

## Artigos de interesse

Artigo referente aos bancos de dados:

<https://arxiv.org/abs/2303.05745>

- Objetivo: definição de um Challenge e uma ampla base de dados para segmentação de imagens de pulmão (segmentação da árvore pulmonar)
- Artigo bem geral, apresenta diversas arquiteturas, mas nenhuma com genAI
- O mais importante é a definição de pontos importantes para o problema de segmentação pulmonar:
  - Topology completeness: a árvore precisa estar completa, do trecho principal as ramificações mais finas e terminações
  - Topology correctness: a árvore segmentada automaticamente precisa coincidir com a anotação dos especialistas
  - Métricas:
    - DSC: proporção do que foi segmentado corretamente em relação a toda área segmentada automaticamente e por especialistas
    - Precisão: do todo segmentado automaticamente, o quanto está correto
    - Sensibilidade: do todo que deveria ter sido segmentado, o quanto realmente foi
    - Especificidade: do todo que não deveria ter sido segmentado realmente não foi
    - TD: o quão longa é a profundidade do maior trecho segmentado automaticamente com relação a profundidade do maior trecho segmentado pelos especialistas
    - BD: quantos ramos foram segmentados com relação a quantos ramos deveriam ter sido segmentados segundo os especialistas

Artigo sobre a síntese de CT Pulmonar com GANs:

<https://www.sciencedirect.com/science/article/pii/S0957417422023685>

- Objetivo: geração de imagens de pulmão a partir de imagens segmentadas que delinearam a posição dos pulmões/imagens com tumor e sem
- Arquitetura: duas arquiteturas:
  - conditional GAN
  - conditional GAN com classificador para identificar a presença de enfisema pulmonar (essa recebe além da imagem a informação semântica das mesmas)
- Dados:
  - LIDC-IDR ([LIDC-IDRI Dataset | Papers With Code](#)) (**PÚBLICO**) imagens CT de pulmão com anotações da posição do pulmão (segmentação) e de nódulos presentes neles
  - NLST Dataset ([NLST - The Cancer Data Access System](#)) (**PRECISA PEDIR ACESSO**) imagens CT com diferentes patologias, incluindo enfisema, e com as anotações dos médicos (o que foi diagnosticado em cada imagem)

- Validação: métrica FID (**achei meio x essa aqui**) passa as imagens reais e sintéticas por um autoencoder e verifica a semelhança entre o vetor que “encoda” as imagens; métrica SSIM comparando imagens reais e sintéticas
- Não achei git do projeto

Review de métodos utilizados para análise de COVID-19 em CTs:

<https://medinform.jmir.org/2022/6/e37365/>

Utilização de redes Auto regressivas para MRIs Encefálicos:

[https://link.springer.com/chapter/10.1007/978-3-030-32251-9\\_47](https://link.springer.com/chapter/10.1007/978-3-030-32251-9_47)

A deep learning approach to generate synthetic CT in low field MR-guided radiotherapy for lung cases

[A deep learning approach to generate synthetic CT in low field MR-guided radiotherapy for lung cases - ScienceDirect](#)

- Objetivo: obter imagens sintéticas de CT a partir de MR para usar no cálculo da dose de radiação para tratamento de radioterapia
- Arquitetura: conditional GAN
- Dados: Coletaram os próprios dados: imagens de MR e CT dos mesmos pacientes em tratamento e no mesmo dia
- Validação: comparação quantitativa das imagens CT adquiridas e sintéticas (MAE, ME), comparação entre a dose de radiação a ser usada calculadas a partir das imagens adquiridas e sintéticas.
- Não achei git do projeto

Generative AI in Medical Imaging: Applications, Challenges, and Ethics

[Generative AI in Medical Imaging: Applications, Challenges, and Ethics | Journal of Medical Systems \(springer.com\)](#)

Artigo bem geral falando sobre como genAI pode ser útil na medicina.

Dois eixos:

- geração de imagens: data augmentation, conversão de imagem de uma modalidade para outra
- LLM: utilização de conteúdo semântico para auxiliar na análise de imagens e diagnóstico

LungSeg-Net:

[LungSeg-Net: Lung field segmentation using generative adversarial network - ScienceDirect](#)

Artigo utilizando uma GAN para segmentar imagens de pulmão.

Partes interessantes:

- Seção 3.2: descrição interessante de um módulo multi-scale dense feature extraction (MSDFE): traz insights interessantes a respeito da formulação das layers.
- Seção de resultados traz imagens interessantes para avaliação qualitativa da segmentação (cores diferentes para over-segmentation e under-segmentation).

## Creating Artificial Images for Radiology Applications Using Generative Adversarial Networks (GANs) – A Systematic Review:

[Creating Artificial Images for Radiology Applications Using Generative Adversarial Networks \(GANs\) – A Systematic Review - ScienceDirect](#)

Artigo de revisão sobre a aplicação de GANs em radiologia.

Algumas passagens de interesse:

- Ideia de loss: Perceptual loss compares extracted features of the generated images against real images, instead of comparing pixel distribution.
- Ideia para o treino da rede de segmentação posterior: The main pitfall in generated images is that they sometimes struggle to compete with real ones. Synthetic images may have low resolution or be blurred. For this reason, algorithm training is initially done using fake images, and then refined with real images. This way benefiting training and decreasing the number of required real images.
- Problemas no treinamento de GANs: In most cases the discriminator is the one that becomes more powerful (*during training*). When this happens the discriminator can easily identify the generated images. Eventually it no longer provides useful output for the generator and the generated images cease to improve. There is also the possibility of complete or partial mode collapse. The generator will synthesize a limited diversity of images or even the same image, regardless of its input. In radiology this can cause the generation of wrong artificial features. The networks can also be biased when there is under or over-representation of certain findings.
- Sobre os artigos da área: published studies ultimately assess technical feasibility, but not practical clinical performance of GANs in radiology.
- Dificuldade em comparar artigos: There is also difficulty in effective assessment and comparison of GANs performance. That is due to the variability in image quality assessment measures between studies. Some use objective numerical metrics of different sorts but those vary between studies. [...] Due to the lack of standardization, some studies use subjective physicians' evaluations of image quality. Others assess down-stream tasks.
- A prestar atenção: Using generated images in clinical practice should be done with caution, as the algorithms are not without limitations. For example, in image reconstruction details can get lost in translation, while fake inexistent details can suddenly appear.